



DOCUMENTO 01 / 05

Arquitectura de la Solución

Componentes, flujo de datos, tecnologías justificadas, seguridad, cumplimiento y escalabilidad. Siete decisiones de arquitectura registradas.

AUTOR

Henry Taborda

FECHA

15 de septiembre de 2026

PROYECTO

Plataforma Ágora

PRUÉBELO

Demo desplegado · <https://agora-esic.vercel.app>

Demo extendido (sesión claude.ai) ·

<https://claude.ai/artifact/4hRWPEMq5yAzW7Ch6q9ts7>

Video narrado · github.com/HenryStark866/Agora-demo-esic → video/

Sin conexión · demo_web/index.html · video/Demo_Fabrica_IA_Henry_Taborda.mp4

Código · carpeta codigo/ · python demo.py · guía en codigo/GUIA_DEMO.md

■ 0. La tesis en un párrafo

El problema de ESIC no es que falte un chatbot. Es que **el conocimiento institucional vive disperso en cabezas, correos y PDFs**, y cada consulta obliga a una persona a reconstruirlo desde cero. Por eso el 60% del tiempo se va en repetir. Un chatbot aislado resuelve el síntoma y crea un nuevo silo. Lo que propongo es una **fábrica**: una plataforma con componentes reutilizables —conocimiento gobernado, orquestación, observabilidad y seguridad— sobre la cual los tres escenarios del caso son los tres primeros productos, y el cuarto, el quinto y el décimo cuestan una fracción del primero. Esa es la diferencia entre automatizar tres procesos y construir una capacidad.

■ 1. Principios de diseño

Cinco decisiones que gobiernan todo lo demás. Cuando haya que elegir, se elige por estos principios.

#	Principio	Qué implica en la práctica
P1	Apalancarse en lo que ESIC ya tiene	El caso menciona <i>sistemas Microsoft</i> . La arquitectura se ancla en Azure y Microsoft 365: Entra ID para identidad, Graph para correo y calendario, Teams como consola del staff. Cero migraciones. El costo de adopción interna cae a casi nada.
P2	Separar conocimiento estático de dato vivo	RAG para lo que cambia poco (pénsums, requisitos, políticas). <i>Function calling</i> contra APIs en vivo para lo que cambia a diario (cupos, precios, fechas de cierre, estado de una solicitud). Un precio jamás sale de un índice vectorial . Esta sola regla elimina la mayor fuente de alucinación con consecuencias comerciales.
P3	El humano decide lo irreversible	La IA clasifica, extrae, redacta y recomienda. Rechazar una admisión, aprobar un documento dudoso o comprometer un descuento siempre pasa por una persona, con el contexto ya preparado.
P4	Portabilidad deliberada	Toda llamada a un modelo pasa por una capa de abstracción propia. Cambiar de <code>gpt-5.4-mini</code> a otro proveedor es un cambio de configuración, no un refactor. ESIC no queda rehén de un modelo ni de un precio.
P5	Si no se mide, no existe	Cada interacción emite trazas de costo, latencia, <i>groundedness</i> y satisfacción. La meta del 70% es un tablero, no una promesa de slide.

2. Vista de capas



3. Componentes y justificación tecnológica

3.1 Capa de inteligencia

Componente	Tecnología elegida	Por qué esta y no otra
Plataforma de modelos	Azure AI Foundry (Azure OpenAI)	No es solo "OpenAI con otra factura". Trae: DPA empresarial y compromiso de no entrenamiento sobre los datos del cliente; integración nativa con Entra ID y Private Link (el tráfico no sale a internet); SLA y facturación dentro del <i>Enterprise Agreement</i> que ESIC probablemente ya tiene. Usar la API pública de OpenAI obligaría a un contrato nuevo, un análisis de transferencia internacional de datos aparte y un vector de red adicional.

Componente	Tecnología elegida	Por qué esta y no otra
Modelo de trabajo	gpt-5.4-mini para ~80% del tráfico	El 80% de las consultas son de recuperación con síntesis corta. Un modelo de razonamiento ahí es quemar presupuesto y latencia.
Modelo de razonamiento	gpt-5.4	Se activa por el router cuando la consulta es multi-salto ("¿qué máster me sirve si vengo de psicología, trabajo de noche y necesito financiación?") o cuando el juicio de confianza del modelo pequeño cae bajo umbral.
Embeddings	text-embedding-3-large (3.072 dim)	La diferencia de costo frente a -small es marginal en este volumen y la ganancia en recuperación sobre español técnico y nombres de programas es real.
Extracción documental	Azure AI Document Intelligence	prebuilt-idDocument , prebuilt-layout y un modelo <i>custom</i> entrenado con actas de grado colombianas. Detalle en el Documento 3.
Seguridad del modelo	Azure AI Content Safety + Prompt Shields	Filtrado de entrada/salida y defensa contra inyección de prompt, incluida la indirecta (un PDF subido que contenga instrucciones).

Estrategia anti-lock-in (P4). Todo pasa por `llm_gateway`, una capa propia que normaliza *requests*, aplica caché, presupuesto por conversación y reintentos con espera exponencial. Detrás puede haber Azure OpenAI, Anthropic, Gemini o un modelo abierto en contenedor. La decisión de modelo es un catálogo de configuración con *routing* por tipo de tarea y techo de costo; el código entregado trae los catálogos de Azure OpenAI y de Gemini, y el demo cambia de uno a otro con un parámetro, sin tocar el orquestador.

3.2 Capa de orquestación — el híbrido y su razón

Esta es la decisión que más se suele equivocar, así que la justifico explícitamente.

Herramienta	Dónde se usa	Por qué
n8n (auto-hospedado en Container Apps)	Flujos de negocio con pasos humanos: validación documental, escalamientos, <i>nurturing</i> de leads, reportes.	Auto-hospedado, los datos personales nunca salen de la suscripción de Azure de ESIC — condición dura bajo Ley 1581. Es visual: un coordinador de admisiones puede leer el flujo y discutirlo. Y tiene nodos de IA nativos. Versionable en Git.
Power Automate	Automatizaciones ligeras <i>dentro</i> de Microsoft 365: aprobaciones en Teams, alertas, SharePoint.	Donde ya hay conector nativo y licencia pagada, escribir código es desperdiciar.
Azure Functions	Procesamiento pesado, criptografía, validaciones deterministas, jobs de reindexación.	Las reglas de negocio críticas (¿este promedio cumple el requisito?) van en código probado con pruebas unitarias, no en un nodo de <i>low-code</i> .

La regla: *low-code* para el flujo y la visibilidad; código para la lógica que, si falla, cuesta dinero o reputación. Meter validación de requisitos de admisión en un nodo visual es cómodo hasta la primera auditoría.

3.3 Capa de conocimiento

Azure AI Search con búsqueda híbrida: BM25 (léxico, imbatible para códigos de programa y nombres propios) + vectorial (semántico) + *semantic ranker* sobre el conjunto fusionado con RRF.

Cada *chunk* indexado lleva metadatos obligatorios:

```
{
  "chunk_id": "prog-mdm-2026-req-03",
  "contenido": "...",
  "vector": [...],
  "fuente_uri": "https://esic.co/programas/master-digital-marketing",
  "tipo": "programa | financiacion | politica | faq | empleabilidad",
  "audiencia": ["aspirante", "estudiante", "egresado", "empresa"],
  "sensibilidad": "publico | interno | restringido",
  "propietario": "coordinacion.academica@esic.co",
  "vigente_desde": "2026-01-15T00:00:00Z",
  "vigente_hasta": "2026-12-31T23:59:59Z",
  "version": 7,
  "hash_origen": "sha256:..."
}
```

`vigente_hasta` no es decorativo: es un **contrato de frescura**. Un *chunk* vencido se excluye del *retrieval* automáticamente y dispara una tarea al propietario. El contenido desactualizado deja de ser un riesgo silencioso y se vuelve un ticket con dueño y fecha.

■ 4. Flujos de datos

4.1 Consulta conversacional (Escenario 1)


```

Usuario → Canal → API Gateway —┬─ AuthN (Entra ID / token anónimo firmado)
                                └─ Rate limit + WAF
                                └─ Orquestador de consulta
                                    └─ [1] Content Safety + Prompt Shields
                                    └─ [2] Router de intención (gpt-5.4-nano)
                                        └─ en dominio → sigue
                                        └─ fuera de dominio → respuesta de política
                                        └─ requiere humano → deriva con contexto
                                    └─ [3] Caché semántica (Redis, umbral 0,94)
                                        └─ acierto → responde (≈40% del tráfico)
                                    └─ [4] Recuperación híbrida (AI Search)
                                        └─ + filtro por audiencia, sensibilidad y vigencia
                                    └─ [5] ¿Requiere dato vivo?
                                        └─ sí → function calling a API del SIA/CRM
                                    └─ [6] Generación con grounding obligatorio + citas
                                    └─ [7] Verificación de groundedness
                                        └─ score < 0,7 → no responde, deriva
                                    └─ [8] Traza: costo, latencia, fuentes, feedback

```

El paso **[7]** es lo que separa una demo de un sistema en producción. Si la respuesta generada no está respaldada por los fragmentos recuperados, **el sistema prefiere no responder**. En una institución educativa, una respuesta inventada sobre requisitos de admisión o condiciones de financiación es un problema legal, no un bug.

4.2 Validación documental (Escenario 2)



4.3 Recomendación de programa (Escenario 3 — a nivel de arquitectura)

Enfoque híbrido en tres etapas: **filtro duro** de elegibilidad (reglas, no IA) → **recuperación** por similitud entre el vector del perfil y el vector de cada programa, enriquecida con datos de empleabilidad de egresados → **re-ranking y explicación** con LLM. El modelo nunca decide solo: ordena y argumenta sobre un conjunto que ya pasó reglas auditables. Desarrollo en el Documento 2 (roadmap) y Documento 3 (sección 4).

■ 5. Seguridad y cumplimiento

ESIC Medellín opera con **doble titulación Colombia–España**. La **Ley 1581 de 2012** aplica con certeza. Para el flujo de datos hacia la institución española, el **RGPD** muy probablemente también aplica — es un punto que hay que confirmar con jurídica en la Fase 0, no asumir. La arquitectura se diseña para cumplir ambos regímenes porque el sobre costo de hacerlo es bajo y el de descubrirlo tarde es alto.

5.1 Protección de datos personales

Exigencia	Implementación
Autorización previa, expresa e informada (art. 9, Ley 1581)	Registro de consentimiento con marca temporal, versión del aviso de privacidad y canal, en tabla append-only. Recuperable en segundos ante requerimiento de la SIC.
Finalidad y minimización	El chatbot anónimo opera sin PII. La identificación solo ocurre cuando el usuario pide algo que la requiere, y pidiendo el mínimo.
Datos sensibles (art. 5–6)	Documentos de identidad y académicos: cifrado en reposo con llave gestionada por el cliente (CMK) en Key Vault, acceso solo vía identidad administrada, retención con borrado automático al cierre del proceso de admisión.
Derechos del titular (consulta, rectificación, supresión)	Endpoint dedicado que resuelve en ≤ 10 días hábiles. La supresión propaga a índices, cachés y trazas.
Transferencia internacional	Despliegue en región Azure con residencia definida y DPA de Azure OpenAI. Los <i>prompts</i> no se usan para entrenar modelos.
Redacción de PII en telemetría	Las trazas guardan <i>hashes</i> y metadatos, no el contenido personal. Un incidente en observabilidad no es una fuga de datos.

Este bloque lo escribo desde experiencia directa: construí **Habeas Check**, una herramienta de autodiagnóstico de cumplimiento de Ley 1581. No estoy citando una norma que leí esta mañana.

5.2 Riesgos propios de IA (OWASP Top 10 para LLM)

Riesgo	Mitigación en esta arquitectura
Inyección de prompt (directa e indirecta)	Prompt Shields; separación estricta instrucción/dato; documentos subidos tratados como contenido no confiable, nunca como instrucciones.
Divulgación de información sensible	Filtro por <code>audiencia</code> y <code>sensibilidad</code> en el <i>retrieval</i> , aplicado antes de que el modelo vea el contexto. La audiencia que propone el router se valida contra una lista cerrada antes de entrar al filtro, para que un mensaje manipulado no pueda inyectar OData. Un aspirante no puede recuperar un documento interno ni con el prompt perfecto.
Salida insegura / alucinación	Grounding obligatorio, umbral de <i>groundedness</i> , citas verificables, negativa explícita cuando no hay evidencia.
Consumo excesivo (costo)	Presupuesto por conversación verificado antes de cada llamada, límite de tokens, caché semántica, rate limiting por IP y por usuario.
Agencia excesiva	Las herramientas expuestas al modelo son de solo lectura . Las pocas escrituras (crear el caso en el CRM, registrar un vacío de contenido, aprobar un documento en el SIA) las ejecutan el orquestador y los flujos con reglas deterministas, nunca el modelo. El modelo no puede modificar un registro académico.
Envenenamiento de datos	Solo se indexa desde fuentes autorizadas con dueño identificado; cada <i>chunk</i> guarda <code>hash_origen</code> .

5.3 Seguridad de infraestructura

Entra ID con MFA para todo acceso administrativo · Private Endpoints: ningún servicio de datos con IP pública · Secretos en Key Vault, rotación 90 días, cero credenciales en código · WAF y APIM al frente · Segregación de ambientes dev/stage/prod con suscripciones separadas · Pentest externo antes de producción (presupuestado) · Registro de auditoría inmutable por 5 años.

■ 6. Escalabilidad

Dimensión	Diseño	Techo antes de rediseñar
Concurrencia conversacional	Container Apps con escalado por longitud de cola KEDA; estado en Redis, contenedores sin estado	~200 conversaciones simultáneas con 1 SU de AI Search
Volumen de consultas	Caché semántica absorbe ~40%; TPM de Azure OpenAI con <i>provisioned throughput</i> si la demanda se vuelve estable	10× el volumen actual sin cambio arquitectónico
Corpus de conocimiento	AI Search S1 → S2 es un cambio de SKU, no de código	~50 GB de índice
Documentos	Procesamiento asíncrono por cola: los picos de temporada de admisiones se absorben con latencia, no con caídas	picos de 10× sobre la media

Dimensión	Diseño	Techo antes de rediseñar
Nuevos casos de uso	Este es el punto. Cada producto nuevo reutiliza autenticación, RAG, orquestación, observabilidad y gobierno.	El escenario 4 cuesta ~20% de lo que costó el primero

Lo que deliberadamente NO se hace ahora: *fine-tuning* (RAG bien hecho resuelve el 95% a una fracción del costo y sin deuda de reentrenamiento); base de datos vectorial propia (AI Search cubre el volumen de ESIC por años); multi-nube (complejidad sin beneficio a esta escala); agentes autónomos con capacidad de escritura amplia (riesgo desproporcionado frente al valor). Cada una de estas puertas queda abierta, ninguna se abre sin una métrica que lo justifique.

■ 7. Decisiones de arquitectura registradas

ID	Decisión	Alternativa descartada	Razón
ADR-01	Azure AI Foundry como plataforma de modelos	API pública de OpenAI / Bedrock	Alineación con el stack Microsoft existente (P1), DPA y residencia, identidad unificada
ADR-02	RAG híbrido, no <i>fine-tuning</i>	Modelo afinado con datos de ESIC	El conocimiento cambia cada semestre; reentrenar es insostenible. RAG actualiza en minutos
ADR-03	n8n auto-hospedado + Functions + Power Automate	Solo Power Automate / solo código	Ver 3.2. Visibilidad para negocio, rigor donde importa, datos dentro de Azure
ADR-04	Datos transaccionales vía <i>function calling</i> , nunca indexados	Indexar todo, incluido precios y cupos	Un precio desactualizado en una respuesta es un compromiso comercial en falso
ADR-05	Capa propia de abstracción de LLM	Llamar el SDK del proveedor directamente	Portabilidad, control de costo y caché centralizados (P4)
ADR-06	Umbral de <i>groundedness</i> con negativa explícita	Responder siempre	Prefiero "no sé, te conecto con admisiones" a una respuesta inventada sobre requisitos
ADR-07	PostgreSQL para estado operativo	Cosmos DB	El modelo es relacional y el volumen no justifica el costo ni la complejidad de Cosmos

■ 8. Cómo esta arquitectura ataca el 70%

Fuente del 60% de tiempo perdido	Componente que lo ataca	Reducción modelada
Consultas repetitivas en cuatro canales	Chatbot RAG multicanal con caché y derivación con contexto	72%
Reapertura y seguimiento de casos	Seguimiento automatizado en n8n + contexto completo al humano	65%
Revisión manual documento por documento	Document Intelligence + validación cruzada + score de riesgo	80%

Fuente del 60% de tiempo perdido	Componente que lo ataca	Reducción modelada
Ciclos de correo por documentos incompletos	Validación en el momento de la carga, antes de enviar	75%
Asesoría manual de elección de programa	Recomendador híbrido explicable	55%
Reportes recurrentes armados a mano	Pipeline programado → Power BI	85%
Conciliación manual entre sistemas	Conectores idempotentes + CDC	80%

Total ponderado: 70,6% sobre 15.462 horas/año de carga base. El cálculo completo, con todos sus supuestos y su análisis de sensibilidad, está en el Documento 4 y en `codigo/modelo_roi.py`, ejecutable. Los pasos del flujo 4.1 y del 4.2 se pueden ver funcionando en el demo interactivo y con `python demo.py`.