



DOCUMENTO 04 / 05

Evaluación de Impacto y ROI

Línea base, reducción del 70,6 % del trabajo manual, costos, ROI en tres vistas, doble sensibilidad y métricas de éxito.

AUTOR

Henry Taborda

FECHA

15 de septiembre de 2026

PROYECTO

Plataforma Ágora

PRUÉBELO

Demo desplegado · <https://agora-esic.vercel.app>

Demo extendido (sesión claude.ai) ·

<https://claude.ai/artifact/4hRWPEMq5yAzW7Ch6q9ts7>

Video narrado · github.com/HenryStark866/Agora-demo-esic → video/

Sin conexión · demo_web/index.html · video/Demo_Fabrica_IA_Henry_Taborda.mp4

Código · carpeta codigo/ · python demo.py · guía en codigo/GUIA_DEMO.md

■ 0. Cómo leer este documento

Todos los números de aquí salen de un modelo que se puede ejecutar y auditar. Cada supuesto es un parámetro editable en la primera sección del archivo; ninguna cifra está escondida dentro de una conclusión. Si ESIC cree que son 500 consultas diarias y no 350, se cambia una línea y el modelo entero se recalcula.

Esa es la postura: **no vengo a defender un número, vengo a entregar el modelo**. Y dos advertencias honestas por delante:

- 1. **Los supuestos de volumen son estimaciones**, porque el caso da magnitudes ("cientos de consultas", "~60% del tiempo") y no datos. La primera actividad de la Fase 0 es medir la línea base real y firmarla con los líderes de área. Hasta entonces, el 70% es una hipótesis con un modelo detrás, no un hecho.
- 2. **El precio de inferencia es el único supuesto que no pude anclar a una fuente pública**. Lo declaro explícitamente (USD 0,015 por interacción) en vez de presentar una cifra inventada como si fuera oficial. Se valida contra la Azure Pricing Calculator en la semana 3.

Fuentes de los parámetros macro

Parámetro	Valor	Fuente
SMMLV 2026	\$1.750.905 COP	Decreto 0159 de 2026, que lo fija transitoriamente tras la suspensión provisional del Decreto 1469 de 2025 por el Consejo de Estado (mismo valor)
Factor prestacional	1,52	Cesantías (8,33%), intereses (1%), prima (8,33%), vacaciones (4,17%), pensión (12%), ARL (0,522%), caja (4%), salud (8,5%), ICBF (3%) y SENA (2%) = 51,85%. Se incluyen salud, ICBF y SENA sin asumir la exoneración del art. 114-1 E.T.: el factor es conservador
Jornada legal	42 h/semana desde 15-jul-2026	Ley 2101 de 2021
Horas productivas/año	1.848	42 h × 44 semanas efectivas
TRM de planeación	\$3.150 COP/USD	TRM 15-sep-2026 = \$3.109,30 + 1,3% de colchón
Document Intelligence	USD 1,50 / 10 / 30 por 1.000 pág.	Precios pay-as-you-go verificados 2026

■ 1. Línea base: dónde se va el tiempo hoy

El caso dice que los equipos dedican ~60% del tiempo a trabajo repetitivo. Traducido a horas, con los supuestos de volumen declarados:

Flujo	Volumen/año	Min/evento	Horas/año
Consultas repetitivas (4 canales)	87.500	8	11.667

Flujo	Volumen/año	Min/evento	Horas/año
Seguimiento y reapertura de casos	19.250	6	1.925
Revisión manual de documentos	1.800	6	180
Ciclos de correo por documentos incompletos	630	30	315
Asesoría manual de elección de programa	1.200	45	900
Reportes recurrentes	72	240	288
Conciliación manual entre sistemas	250	45	188
TOTAL			15.462 h/año

Equivale a 8,4 FTE. Costo anual de esa carga: **\$811.589.946 COP**.

Un hallazgo que cambia la prioridad del proyecto. La revisión manual de documentos —el dolor que el caso describe con más detalle (2 h por 20 solicitudes)— son apenas **180 horas al año**. Las consultas repetitivas son **11.667**: sesenta y cinco veces más. Si hubiera que elegir un solo escenario para construir, el orden correcto es 1 → 2 → 3, y por eso el MVP de la semana 12 es el chatbot. Los ciclos de correo por documentos incompletos (315 h) cuestan casi el doble que la revisión en sí: **el problema documental no es revisar, es el ida y vuelta**, y por eso la validación ocurre en el momento de la carga.

■ 2. Reducción de trabajo manual

Flujo	Deflexión	Horas liberadas	Cómo
Consultas repetitivas	72%	8.400	RAG multicanal + caché semántica (~40% de aciertos)
Seguimiento y reapertura	65%	1.251	Seguimiento automatizado + <i>handoff</i> con contexto completo
Revisión de documentos	80%	144	5 capas de validación + auto-aprobación sobre score ≥ 85
Ciclos de correo	75%	236	Validación en el momento de la carga, antes de enviar
Asesoría de programa	55%	495	Recomendador explicable; el asesor conserva la decisión
Reportes recurrentes	85%	245	Pipeline programado → Power BI
Conciliación entre sistemas	80%	150	Conectores idempotentes + CDC
TOTAL PONDERADO	70,6%	10.921 h/año	

Meta del caso: 70% · Resultado modelado: 70,6%

5,9 FTE de capacidad liberada. Valor: **\$574.675.672 COP/año**.

Las tasas de deflexión no son aspiracionales: 72% en consultas está dentro del rango que alcanza un RAG bien gobernado sobre un dominio acotado con contenido curado. Las tres condiciones importan — sin curaduría de contenido, la cifra real está 20 puntos abajo, y por eso el rol de Knowledge Ops está financiado desde el día uno (riesgo R1).

■ 3. Costo de operar la plataforma

Componente	USD/año	COP/año
Azure OpenAI — inferencia (74.375 interacciones)	1.116	3.514.219
Azure OpenAI — embeddings y reindexación	420	1.323.000
Azure AI Search (S1, 1 SU) <i>[estimado]</i>	3.000	9.450.000
Azure AI Document Intelligence (12.600 pág.)	198	623.700
Azure Container Apps (n8n + APIs)	1.450	4.567.500
Functions, Storage, Key Vault, Monitor	980	3.087.000
Content Safety + evaluaciones continuas	620	1.953.000
WhatsApp Business API	2.400	7.560.000
TOTAL	10.184	32.078.419

Costo por consulta	
Atendida por IA	\$431 COP
Atendida a mano	\$6.913 COP
Relación	1 : 16

El dato que más cuesta creer y más conviene entender: operar toda la plataforma cuesta **\$32 millones de pesos al año** — menos que un solo analista. El costo de una Fábrica de IA no son los tokens: es el equipo, la curaduría de contenido y la gobernanza. Cualquier caso de negocio que presente la nube como el gasto principal está mirando el lugar equivocado, y cualquier proveedor que venda "ahorro en infraestructura" no ha construido uno de estos.

■ 4. Inversión año 1

Concepto	COP
Ingeniero de IA / Backend (nuevo, 11 meses)	190.288.355
Ingeniero de Automatización (nuevo, 9 meses)	131.738.092
Pentest externo, licencias, formación, contingencia 15%	42.000.000
Run rate de plataforma	32.078.419
VISTA A — costo incremental año 1	396.104.866
+ Director de Fábrica de IA (12 meses)	287.428.565

Concepto	COP
+ Knowledge Ops 50% y Product Owner 25% (internos)	103.793.649
VISTA B — costo totalmente cargado año 1	787.327.080

Por qué dos vistas, y por qué la A es la correcta para decidir. El Director de Fábrica de IA es una contratación que ESIC **ya decidió hacer** — es el cargo de este proceso de selección. Cargarlo al proyecto sería contar dos veces una decisión ya tomada. Knowledge Ops y el Product Owner son personal interno reasignado, no headcount nuevo. La Vista B se incluye porque un CFO la va a pedir, y porque presentar solo la cifra favorable sería hacer trampa con la contabilidad.

■ 5. ROI

5.1 Solo por eficiencia operativa

Período	Beneficio	Costo	Neto	ROI
Año 1 (Vista A)	280.154.390	396.104.866	-115.950.476	-29,3%
Año 1 (Vista B)	280.154.390	787.327.080	-507.172.689	-64,4%
Año 2	574.675.672	415.316.505	+159.359.167	+38,4%
Año 3	574.675.672	415.316.505	+159.359.167	+38,4%

Payback: mes 21. ROI acumulado a 3 años: +16,5%.

El beneficio del año 1 es parcial porque el valor se materializa progresivamente: nada en los primeros 3 meses, 15% desde el MVP en la semana 12, 100% desde el mes 10.

Y aquí está la conversación incómoda que hay que tener de frente: *si el caso de negocio fuera solo eficiencia operativa, este proyecto sería marginal.* Un ROI de 38% al año 2 con payback en el mes 21 es aceptable, no espectacular. Presentarlo con un 300% sacado de sumar beneficios blandos sería más vendedor y menos cierto.

El caso de negocio de una escuela de negocios no es el costo. Es la conversión.

5.2 Donde está el valor real: la palanca de ingreso

El cuello de botella de ESIC no es que admisiones trabaje mucho. Es que **un aspirante que pregunta un sábado a las 9 de la noche recibe respuesta el lunes**, y para entonces ya cotizó en otras dos escuelas. Con ~9.000 leads al año y 1.200 matrículas (13,3% de conversión), cada punto de conversión son 90 matrículas.

Un lift conservador de **+1,5 puntos porcentuales** — por respuesta inmediata 24/7, seguimiento automatizado que no se cae y asesoría enriquecida — son **135 matrículas incrementales al año**:

Ticket promedio anual	Ingreso incremental	Margen de contribución (45%)	ROI año 2 total
\$14.000.000	\$1.890.000.000	\$850.500.000	243%
\$22.000.000	\$2.970.000.000	\$1.336.500.000	360%

Ticket promedio anual	Ingreso incremental	Margen de contribución (45%)	ROI año 2 total
\$30.000.000	\$4.050.000.000	\$1.822.500.000	477%

El ticket promedio lo pone ESIC. No lo invento: entrego la palanca y el modelo, y ESIC sustituye su cifra real. Con cualquiera de los tres escenarios, **entre 3 y 6 matrículas incrementales pagan el run rate anual completo de la plataforma** (\$32 millones); las 135 del escenario lo cubren más de 25 veces. El costo completo del año 2, equipo incluido, se paga con entre 31 y 66 matrículas.

■ 6. Análisis de sensibilidad

6.1 Qué pasa si no llegamos al 70%

Deflexión lograda	Ahorro anual	ROI año 2 (solo eficiencia)
40%	\$324.635.978	-21,8%
50%	\$405.794.973	-2,3%
60%	\$486.953.967	+17,2%
70%	\$568.112.962	+36,8%
80%	\$649.271.956	+56,3%

Punto de equilibrio: 51,2% de deflexión. Por debajo de eso, el proyecto no se paga solo con eficiencia. Aun con 40% de deflexión, el faltante se cubre con unas 14 matrículas incrementales al ticket más bajo: una décima parte de la meta de conversión.

Esto es lo que quiero que quede claro: **el proyecto tiene un margen de error de casi 20 puntos porcentuales sobre la meta antes de volverse negativo.** Eso no es optimismo; es diseño de riesgo.

6.2 Sensibilidad al volumen — el supuesto más frágil de todo el modelo

La deflexión no es el riesgo mayor. El riesgo mayor es que "*cientos de consultas diarias*" sea una magnitud y no un dato. Modelé 350 como extremo bajo del rango, pero si ESIC Medellín —un campus relativamente joven— recibe la mitad, el ahorro cae proporcionalmente y el caso cambia:

Consultas/día	Carga base (h/año)	Ahorro anual	ROI año 2	Veredicto
100	5.754	\$217.269.347	-47,4%	No se paga solo
150	7.696	\$288.750.612	-30,1%	No se paga solo
200	9.637	\$360.231.877	-12,9%	No se paga solo
250	11.579	\$431.713.142	+4,2%	Marginal
350 (modelado)	15.462	\$574.675.672	+38,4%	Se paga solo
500	21.287	\$789.119.467	+89,3%	Se paga solo

El costo de inferencia se recalcula con cada volumen, aunque pesa poco frente al del equipo.

La lectura honesta: el punto de equilibrio está en 238 consultas diarias. Por debajo de unas 240, este proyecto no se justifica solo por eficiencia operativa y tiene que sostenerse en la palanca de conversión de la sección 5.2. Por eso la primera actividad de la Fase 0 es medir el volumen real durante dos semanas, y por eso el GO/NO-GO 1 exige una línea base firmada antes de comprometer el presupuesto completo.

Prefiero entregar esta tabla que un número único. Si ESIC sustituye su cifra real en `codigo/modelo_roi.py`, el modelo entero se recalcula en un segundo.

■ 7. Beneficios por tipo de usuario

Usuario	Antes	Después
Aspirante	Formulario, espera 24–48 h, respuesta genérica, abandona	Respuesta en segundos, 24/7, en WhatsApp, con su caso y su contexto
Estudiante	Correo a coordinación, espera, seguimiento manual	Autoservicio inmediato para el 70% de los trámites
Egresado	Sin canal claro; la relación se enfría al graduarse	Puerta permanente: educación continua, bolsa de empleo, red. Reactiva un activo que ESIC ya tiene y no está usando.
Empresa aliada	Correo comercial, respuesta en días	Calificación inmediata + propuesta preliminar el mismo día
Equipo de admisiones	60% del tiempo repitiendo lo mismo	Lo repetitivo lo absorbe el sistema; el tiempo se va a los casos que necesitan una persona
Dirección	Reportes manuales, decisiones con datos de la semana pasada	Tablero en vivo: demanda por programa, vacíos de contenido, conversión por canal

Un beneficio que no está en ninguna tabla: el sistema registra **qué pregunta la gente y qué no sabe responder ESIC**. Eso es investigación de mercado continua y gratuita sobre demanda real de programas. Para una escuela de negocios que diseña oferta académica, ese dato vale por sí solo.

■ 8. Métricas de éxito

Ninguna métrica sin línea base y sin dueño. Se revisan mensualmente en el comité.

Negocio

Métrica	Línea base	Meta 6 m	Meta 12 m
Reducción de trabajo manual	0%	45%	70%
Tiempo de primera respuesta	24–48 h	< 1 min (IA)	< 1 min
Tasa de resolución sin humano	0%	60%	72%
Conversión lead → matrícula	13,3%	+0,8 pp	+1,5 pp
Satisfacción (CSAT) del asistente	—	≥ 4,0/5	≥ 4,3/5

Métrica	Línea base	Meta 6 m	Meta 12 m
Documentos auto-aprobados	0%	50%	80%
Ciclo de admisión (días)	línea base F0	-30%	-50%

Calidad de IA — las que evitan un desastre

Métrica	Umbral	Acción si se incumple
<i>Groundedness</i> promedio	≥ 0,85	Bloquea despliegue
Acierto en conjunto dorado	≥ 85%	Bloquea despliegue
Tasa de alucinación detectada	< 1%	Revisión inmediata de prompts
Fuga de contenido restringido	0	Incidente de seguridad
Acuerdo IA–humano en documentos	≥ 95%	Suspende auto-aprobación
Disparidad demográfica (recomendador)	no significativa	Bloquea exposición

Operación

Métrica	Meta
p95 de latencia (chatbot)	< 4 s
Disponibilidad	≥ 99,5%
Costo por interacción	< \$500 COP
Vacíos de contenido resueltos / detectados	≥ 80% mensual

La métrica que vigilo más de cerca no es el ahorro: es la fuga de contenido restringido. Es la única con umbral cero, porque las demás se corrigen y esa se lamenta.

■ 9. Lo que puede salir mal con estos números

En orden de probabilidad:

1. **El volumen real es menor que el estimado.** "Cientos de consultas" podría ser 150 y no 350 — y en ese caso, como muestra la tabla 6.2, el proyecto no se paga solo con eficiencia. **Es el riesgo más grande del caso de negocio, por encima de cualquier riesgo técnico.** *Mitigación:* la medición de la Fase 0 corrige el modelo antes de comprometer el presupuesto completo, y el GO/NO-GO 1 lo bloquea si no cuadra.
2. **La capacidad liberada no se reinvierte.** Si nadie define en qué trabajan esas 5,9 FTE, el ahorro es teórico y no aparece en ningún estado financiero. **Es el otro gran riesgo del caso de negocio, y tampoco es técnico.** Requiere una decisión explícita de dirección antes de la semana 12.
3. **El lift de conversión no se materializa.** Depende de que la experiencia sea buena, no solo rápida. *Mitigación:* medición A/B desde el MVP.
4. **El contenido fuente está peor de lo esperado** y la deflexión se queda en 50%. *Mitigación:* auditoría en Fase 0 y GO/NO-GO 1 explícito.

Sobre el punto 2 quiero ser claro incluso a costa de la propuesta: la reducción del 70% no se traduce en ahorro contable a menos que ESIC decida qué hacer con el tiempo liberado. La recomendación es reasignar a trabajo de conversión y experiencia, no reducir personal — porque es ahí donde está el ROI de tres dígitos de la sección 5.2, y porque un equipo que teme por su puesto sabotea pasivamente el proyecto que lo amenaza (riesgo R2). **El caso de negocio y la gestión del cambio son el mismo problema.**